

《模式识别 A》期末实验报告

专业年级 人工智能 24

班 级

学号姓名

实验名称 基于结构先验与混合特征的
极小样本车牌数字识别系统

注：此报告为学生制作报告的模板，教师在批改学生报告（纸质或电子）后，按评分标准进行评分并留下批阅痕迹，然后按“苏州科技大学学生实验个人得分表”模板规范，对每位学生的报告进行评价，填写得分表，然后将得分表与学生报告一一对应，进行归档。

2026 年 6 月 16 日

基于结构先验与混合特征的极小样本车牌数字识别系统

摘 要

针对智能交通系统(ITS)中特定场景下面临的极小样本车牌数字识别任务,本文提出了一套高度可解释、完全可复现的多阶段混合识别框架。在缺乏大规模标注数据的受限条件下,传统的深度学习端到端模型往往面临严重的过拟合风险,且缺乏预测过程的透明度。

为此,本文首先提出了一种结合颜色空间先验与横向局部梯度密集性的自适应车牌定位算法,随后根据车牌底色分布动态选择二值化策略以完成高精度的字符分割。在特征提取与识别阶段,本研究在仅有 10 张标准数字模板的极端条件下,通过可控仿射与形态学扰动将训练集扩增至 910 个样本,并创新性地提出融合方向梯度直方图(HOG)、行列投影分布、前景密度及宽高比的结构化联合特征。利用支持向量机(SVM)进行高维空间的大间隔分类后,本文进一步引入基于归一化模板相关度和局部笔画密度分析的结构后处理模块,有效抑制了在小样本下极易发生的 0/9、3/8、5/6 等相似字形的混淆现象。

实验结果表明,在经过严格的脚本核验后,该系统在纯净样本上数字识别率达到 100.0%;在包含复杂干扰(强反光、背景招牌、尺度变化)的仿真样本上,数字定位 F1 分数与仿真样本目标数字端到端识别准确率均达到 83.33%。横跨全数据集的总体目标数字准确率达到 93.75%(15/16)。相较于单一的模板匹配方法,本文方法在逻辑可解释性、复杂背景抑制及结果可追溯性上展现出显著优势,并对仿真干扰下的单字拓扑失效进行了深刻的错误根源剖析,为小样本条件下的车牌字符识别提供了一种兼具工程鲁棒性与科研严谨性的完整解决方案。

关键词 自动车牌识别; 极小样本学习; 方向梯度直方图; 支持向量机; 自适应字符分割; 结构启发后处理

Few-shot License Plate Digit Recognition System Based on Structural Priors and Hybrid Features

Abstract

To address the challenges of few-shot license plate digit recognition in specific scenarios of Intelligent Transportation Systems (ITS), this paper proposes a highly interpretable and fully reproducible multi-stage hybrid recognition framework. Under data-constrained conditions lacking large-scale labeled samples, traditional end-to-end deep learning models suffer from severe overfitting risks and a deficiency in prediction transparency.

To overcome these limitations, an adaptive license plate localization algorithm is first developed by combining color space priors with lateral local gradient density. Subsequently, a binarization strategy is dynamically selected based on the license plate background color distribution to achieve high-precision character segmentation. During the feature extraction and recognition phase, under the extreme condition of having only 10 standard digit templates, the training set is expanded to 910 samples using controllable affine and morphological perturbations. Concurrently, a structured joint feature vector is innovatively constructed by fusing the Histogram of Oriented Gradients (HOG), row-column projection distributions, foreground density, and aspect ratio. Following large-margin classification via a Support Vector Machine (SVM) in the high-dimensional feature space, a structural post-processing module governed by normalized template correlation and local stroke density analysis is introduced. This module effectively suppresses the confusion of structurally similar glyphs (e.g., 0/9, 3/8, and 5/6) that frequently plagues few-shot learning scenarios.

Experimental results from the execution script demonstrate that the proposed system successfully achieves a pure digit accuracy of 100.0%. On simulated samples with complex interferences (such as intense reflections and distracting background

signage), the real digit detection F1-score and real digit recognition accuracy both reach 83.33%, yielding an overall target digit recognition accuracy of 93.75% (15/16) across the evaluated few-shot closed-set dataset. Compared with conventional single template matching methods, the proposed approach exhibits significant advantages in logical interpretability, background noise suppression, and result traceability.

Keywords Automatic Number Plate Recognition (ANPR); Few-shot learning; Histogram of Oriented Gradients (HOG); Support Vector Machine (SVM); Adaptive character segmentation; Structurally-inspired post-processing.

目 录

第 1 章 引言	1
第 2 章 问题建模	2
第 3 章 核心方法论	3
3.1 车牌定位与自适应字符分割	3
3.2 字形规范化与高维空间特征提取	4
3.3 支持向量分类与结构启发式后处理	5
第 4 章 实验设计与评估协议	7
4.1 数据集与环境配置	7
4.2 评价指标定义	7
第 5 章 结果分析与讨论	8
5.1 模型超参数寻优	8
5.2 系统架构消融分析	9
5.3 综合端到端识别性能	10
第 6 章 局限性与未来展望	12
结 论	14
致 谢	15
参 考 文 献	16

第1章 引言

自动车牌识别 (Automatic Number Plate Recognition, ANPR) 作为现代智能交通系统 (ITS) 的核心模块, 在电子收费、交通流量监测以及公共安防等领域发挥着不可替代的作用。随着深度学习技术的飞速发展, 基于卷积神经网络 (CNN) 与循环神经网络 (RNN) 的端到端识别模型 (YOLO 系列联合 CRNN) 在开放场景下取得了令人瞩目的成就。

然而, 在特定的工业或实验场景中, 任务往往具有极强的先验约束与极端的数据匮乏特征。例如, 在本实验任务中, 纯净样本的后五位全部为固定格式的数字, 而仿真样本则面临着强反光、复杂的背景招牌干扰、车身纹理以及尺度畸变等极具挑战性的成像条件。更为严苛的是, 系统可用的训练集仅包含 0 至 9 共 10 张标准模板图像。在这种极小样本的设定下, 参数量庞大的深度学习模型极易陷入过拟合的陷阱, 将训练模板的噪声或特定字体特征视为全局特征, 进而导致在面临仿真测试集时产生严重的泛化灾难。若直接采用传统的固定阈值分割或简单的全图模板匹配, 则不可避免地会将非车牌文字或车牌边框误认为是目标数字。

基于上述挑战, 本文的核心研究动机在于: 如何将显式的任务先验知识 (格式语法) 编码入完全可解释的算法流程中, 并通过结构化特征工程弥补训练样本规模的不足。

本文的主要贡献可归纳为以下三点:

1. 提出了一种抗干扰的自适应车牌定位与分割机制, 融合颜色阈值先验与 Sobel 横向梯度特征, 有效排除了仿真图中的背景招牌干扰。
2. 构建了适用于小样本学习的混合特征提取空间, 在进行确定性随机种子驱动的模板扩增后, 将高维 HOG 特征与行列投影、前景密度、宽高比拼接, 训练特征矩阵维度达 910×790 。
3. 针对 SVM 在小样本下对相似数字分类边界模糊的问题, 结合归一化模板相关度和关键区域笔画密度校验, 使系统在给定闭集测试集上达到 93.75% 的总体目标数字准确率; 其中纯净样本达到 100.0%, 仿真复杂样本的数字检测 F1 和识别准确率均为 83.33%。

第2章 问题建模

车牌数字识别本质上是一个在具有强噪声的三维张量空间中寻找特定语义目标的序列解码问题。给定一张输入的原始 RGB 图像 $I \in \mathbb{R}^{H \times W \times 3}$ ，系统的终极目标是在该图像中定位出车牌的精确区域，并在该区域内提取出符合语法规则的后五位字符序列中的数字子集，最终输出其对应的类别标签 $y \in \{0, 1, \dots, 9\}$ 。




图 1：任务先验约束下的车牌数字识别流程。流程将定位、分割、字形归一化、分类融合和闭集输出分为可检查模块。

设候选的车牌边界框（Bounding Box）为 $b = (x, y, w, h)$ ，在成功提取该区域并进行字符分割后，可以得到一组按照空间自左向右排列的有序字符集合 $C = \{c_1, c_2, \dots, c_n\}$ 。为了从海量背景噪声中筛选出真实的候选车牌框，本文定义了一个基于多维启发式规则的车牌候选框综合评分函数 $S_{plate}(b)$ ：

$$\begin{cases} b^* = \arg \max_b S_{plate}(b) \\ S_{plate} = \alpha N_{char} + \beta R_{aspect} + \gamma R_{area} + \delta R_{position} \end{cases} \quad (2.1)$$

其中，参数解释如下：

- N_{char} ：量化指标，表示该候选区域中通过连通域分析后可有效分割的独立字符数量，用以验证其是否符合标准车牌的版式先验。
- R_{aspect} ：长宽比一致性惩罚项，由于我国标准车牌的长宽比基本固定（ $440mm \times 140mm$ ），偏离该比例的候选框将被施加极大的惩罚。
- R_{area} 与 $R_{position}$ ：分别代表对候选框相对图像总面积的占比约束，以及在图像中出现的空间位置分布约束。
- $\alpha, \beta, \gamma, \delta$ ：对应的归一化权重系数。

此外，题目提供了极其宝贵的先验约束条件：纯净样本的后五位均为数字；而仿真样本由于环境遮挡或污损，其后五位中仅保证恰好存在三位数字。

为了将这一离散的“语法先验”转化为可排序、可比较的评分约束，本文定义

了如下的位置过滤集合：

$$\begin{cases} D_{clean} = \{c_n - 4, \dots, c_n\} \\ D_{real} = TopK_{i \in \{n-4, \dots, n\}}[p_{digit}(c_i)], K = 3 \end{cases} \quad (2.2)$$

式中， $p_{digit}(c_i)$ 表示模型判定字符 c_i 属于数字的后验置信度。

第3章 核心方法论

本系统采用级联式多阶段流水线架构，涵盖预处理、区域提议、规范化特征提取、分类与后验证五个核心模块。所有的确定性预处理流程及随机扩增种子均设定为 20260616，以确保实验结果在相同环境下具有可复现性。

3.1 车牌定位与自适应字符分割

由于自然场景下的光照具有高度的不确定性，单一的颜色阈值往往导致大量假阳性（如蓝色的广告牌或天空）。因此，本系统采用颜色候选与边缘候选双轨并行的定位策略。

在颜色维度，系统将图像从 RGB 空间映射至更为符合人类视觉感知且对光照解耦的 HSV 空间，并提取蓝色连通域掩膜：

```
mask = cv2.inRange(hsv, np.array([90, 35, 25]), np.array([140, 255, 255]))
```

这段代码在 HSV 空间中进行蓝色范围检测：

- 1) H 通道（色调）：90°~140°对应蓝色至蓝紫色附近的色调范围；
- 2) S 通道（饱和度）：35 以上确保不是褪色区域；
- 3) V 通道（亮度）：25 以上排除过暗区域。

在边缘维度，由于车牌区域具有典型的“垂直边缘丰富且横向密集排列”的纹理特征，本文采用一阶偏导数算子 Sobel 计算横向梯度以突出字符的密集区域：

$$\begin{cases} G_x = \frac{\partial I}{\partial x}, G_y = \frac{\partial I}{\partial y} \\ M(x, y) = \sqrt{G_x^2 + G_y^2} \\ \theta(x, y) = \text{atan2}(G_y, G_x) \end{cases} \quad (3.1)$$

随后，利用形态学闭运算（Morphological Closing）将这些密集的细小边缘桥接成一个完整的连通块（Blob）：


```

closed = cv2.morphologyEx(
    threshold,
    cv2.MORPH_CLOSE,
    cv2.getStructuringElement(cv2.MORPH_RECT, (17, 5)),
    iterations=2,
)
closed = cv2.morphologyEx(closed, cv2.MORPH_OPEN,
cv2.getStructuringElement(cv2.MORPH_RECT, (3, 3)), iterations=1)

```

该代码中，结构元(17,5)的设计意图是：水平方向 17 像素，跨越字符间距，桥接相邻字符边缘；垂直方向 5 像素，保持车牌上下边界的完整性。

两种候选区域经式 S_{plate} 评分后合并，选取全局最高得分的边界框作为最终的车牌定位结果。在字符分割阶段，为了对抗不同光照带来的对比度衰减，系统设计了一种底色自适应的二值化评估器：针对蓝底车牌，并行计算大津法(Otsu)、顶帽形态学增强(Top-hat)、HSV 亮度阈值以及自适应高斯阈值的掩膜响应，并动态评估各掩膜下连通域的几何合规性，最终自动挂载字符数量最为合理的掩膜策略。



图 2：4 张测试图像的定位与后五位筛选结果。绿色框表示进入目标数字评价的槽位，红色框表示仿真样本中被排除的非数字槽位。

3.2 字形规范化与高维空间特征提取

从原始图像截取的字符切片(Glyph)往往伴随不同程度的倾斜与尺度变化。为此，进入特征提取管线前，所有提取的字符必须经过严格的空间对齐。本文首先裁剪掉多余的零像素（非笔画）边界，按照保持纵横比的策略将其缩放并居中

填充至标准画布 $\mathbb{R}^{32 \times 64}$ 中。

为了在极小样本集上训练出鲁棒的分类超平面，单一的像素级特征显然是不够的。本文构建了融合局部方向纹理与全局几何拓扑的混合特征向量 $\varphi(c)$ ：

$$\varphi(c) = [HOG(c), P_{row}(c), P_{col}(c), \rho(c), a(c)] \quad (3.2)$$

该向量作为字符分类的核心输入特征，各分支特征的具体设计原理与计算方式分述如下：

1. HOG 局部梯度纹理特征

HOG 特征具备优异的平移不变性与光照鲁棒性，能够抵抗字符微小形变、亮度波动带来的干扰。其核心思想是将字符图像划分为多个互不重叠的局部空间单元（Cell），在每个单元内统计梯度方向分布频次，单方向分箱统计公式：

$$h_{r,b} = \sum_{(x,y) \in cell_r} M(x,y) \cdot I[\Theta(x,y) \in bin_b] \quad (3.3)$$

式中， $h_{r,b}$ 代表第 r 个 Cell 内、第 b 个角度分箱的梯度累加幅值； $M(x,y)$ 、 $\Theta(x,y)$ 分别为像素梯度幅值与梯度方向角； $I[\cdot]$ 为指示函数。

2. 行列投影分布特征 P_{row} 、 P_{col}

对二维字符字形分别沿水平、竖直两个方向做笔画像素一维投影累加，再通过双线性插值将投影序列压缩至固定维度，以此刻画字符整体骨架轮廓形态。

3. 全局几何标量特征(ρ 、 a)

提取两项全局几何数值，前景笔画像素密度 ρ 、字符外接包围框宽高比 a 。该组特征可快速区分笔画疏密、外形比例差异明显的字符，补充拓扑维度判别依据。

3.3 支持向量分类与结构启发式后处理

为了从 10 张原始模板中榨取尽可能多的数据分布信息，本文通过引入小角度旋转（ $\theta \in [-5^\circ, 5^\circ]$ ）、亚像素平移、尺度缩放、形态学腐蚀与膨胀以及高斯轻度模糊，构建了一个包含 910 个样本的扰动验证空间（Augmented Space）。

分类器引擎选用了支持向量机（SVM）。与深度神经网络旨在最小化经验交叉熵不同，SVM 的核心是在高维特征空间中寻找最大化类间边界（Margin）的超平面。给定特征向量集合与标签，线性核 SVM 的软间隔目标函数可描述为受

约束的凸优化问题：

$$\begin{aligned} \min_{w, \xi} & \frac{1}{2} \|w\|_2^2 + C \sum_i \xi_i \\ \text{s.t.} & y_i(w^T \varphi_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \end{aligned} \quad (3.4)$$

其中 C 为正则化惩罚系数，用以权衡训练误差与模型复杂度。

考虑到支持向量机是全局数据的超平面分割，在小样本场景下对极为相似类别（如“0/9”、“3/8”、“5/6”）可能会发生决策边界的偏移。因此，系统引入了结构启发式后处理（Structural Post-processing）。首先，计算测试字符 c 与标准模板 t_d 之间的零均值归一化互相关（ZNCC）相似度：

$$r_d(c) = \text{corr}(c, t_d) = \frac{\langle c - \mu(c), t_d - \mu(t_d) \rangle}{\|c - \mu(c)\|_2 \cdot \|t_d - \mu(t_d)\|_2} \quad (3.5)$$

最终的预测类别 $\hat{y}$ 并非单一依赖 SVM，而是融合了 SVM 输出后验概率分布 p_{SVM} 与模板相关度的贝叶斯加权平滑结果：

$$\hat{y} = \arg \max_d \left[0.60 \cdot p_{SVM}(d|c) + 0.40 \cdot \frac{r_d(c) + 1}{2} \right] \quad (3.6)$$

对于极易混淆的个例，算法还进行了轻量级的拓扑结构修正。例如，数字“0”是一个连续的闭环，而数字“9”则在右侧中下部拥有一个延伸的尾部笔画。程序提取待测字符特定网格的局部密度，若原本判定为“0”，但模板相关度显示“9”也具有高相似度，且右中网格密度显著大于左中网格密度，则逻辑器将强行干预将其修正为“9”。

第4章 实验设计与评估协议

4.1 数据集与环境配置

实验所用基础数据全部源于给定的 Project 文件夹，包含用于生成扩增矩阵的 0-9 标准模板图像，以及 4 张实际测试图像（纯净样本 plate_1.jpeg、plate_2.jpeg，仿真复杂样本 real_1.jpg、real_2.jpg），纯净样本后五位均为数字；仿真样本后五位中包含非数字干扰，仅其中三位为目标数字。

4.2 评价指标定义

为避免只用单一准确率掩盖错误来源，本文构建了以下四个核心评价指标：

1. **纯净样本数字识别率**：在理想背景下的字形分类绝对准确率（Accuracy）。
2. **仿真样本数字定位 F1 分数**：由于仿真图后五位存在非数字干扰，此项被建模为“该后五位字符区域是否包含数字”的二分类任务，计算查准率（Precision）与查全率（Recall）的调和平均数：

$$F1 = 2 \cdot \frac{P \cdot R}{P + R} \quad (4.1)$$

3. **仿真样本目标数字端到端识别准确率**：剥离定位误差后，纯粹考核分类器在仿真模糊条件下的抗畸变能力。
4. **总体目标数字准确率**：横跨所有测试集的综合终极指标。

评价指标包括纯净样本数字识别率、仿真样本数字/非数字定位 F1、仿真样本已定位数字识别率，以及所有目标数字上的闭集准确率。本报告中的所有指标均只针对给定 4 张样例图像及其 16 个目标数字进行评价，不代表系统在大规模开放道路场景中的泛化性能。

第5章 结果分析与讨论

5.1 模型超参数寻优

在确认系统整体架构前，本研究首先针对支持向量机（SVM）的底层超参数进行了网格搜索与寻优。实验对比了不同核函数与惩罚系数 C 下，增强模板验证集与实际分割字形验证集上的性能表现，其结果分布详见表 1 所示。

模型配置 (SVM Kernel & C)	增强模板验证集准确率	分割数字验证集准确率
linear_C0.5 (本系统采用)	100.0%	87.50%
linear_C1	100.0%	87.50%
linear_C3	100.0%	87.50%
rbf_C3_scale	100.0%	81.25%
rbf_C10_scale	100.0%	81.25%
rbf_C30_scale	100.0%	81.25%

表 1：不同 SVM 超参数在不同验证集上的表现分布。表中的“分割数字验证集准确率”用于模型选择阶段的超参数比较；最终端到端测试性能以后文给定 4 张测试图像上的运行结果为准。

实验结果表明，所有模型配置在增强模板验证集上均达到了 100.0% 的准确率，说明由数据增强生成的样本空间具有较强的规律性，在当前高维特征表示下能够被较好地地区分。然而，当模型面对包含光照变化、字符形变与分割噪声的真实车牌分割字形验证集时，不同核函数的性能出现了明显差异。三组线性核模型在该验证集上的准确率均达到 87.50%，整体优于非线性 RBF 核模型的最高准确率 81.25%。

这一结果说明，本文构建的混合特征向量已经在一定程度上形成了较好的线性可分结构。HOG 特征能够刻画字符局部梯度纹理，行列投影、前景密度与宽高比等几何特征则补充了字符整体轮廓信息，使线性分类器即可获得较好的判别效果。相比之下，RBF 核虽然具有更强的非线性拟合能力，但在极小样本条件下

更容易受到扩增样本分布和分割噪声的影响,导致其在真实分割字形上的表现不如线性核模型稳定。

由于 `linear_C0.5`、`linear_C1` 和 `linear_C3` 在分割数字验证集上取得了相同的最高准确率,本文综合考虑模型复杂度与泛化稳定性,最终选择正则化约束更强、模型相对更简洁的 `linear_C0.5` 作为后续端到端实验的分类模型。




图 3: HOG-SVM 超参数比较。增强模板验证均达到 100%, 但真实分割字形验证只有 81.25%-87.50%, 说明难点来自从车牌图像切出的字形, 而非模板扩增集本身。

5.2 系统架构消融分析

为验证本文所提出的多阶段混合识别架构的必要性与有效性,本研究在闭集目标数字上开展了逐步引入策略的消融实验,以比较不同模块对最终识别性能的影响。

在仅使用基础模板匹配策略时,系统难以充分应对真实车牌图像中的光照变化、字符形变与分割噪声,因而准确率相对较低。当引入线性 SVM 分类器后,模型能够利用 HOG、行列投影、前景密度和宽高比等高维混合特征进行判别,识别准确率获得了明显提升,说明机器学习分类器相较于单一模板匹配具有更强的鲁棒性。

随后,本文进一步将 ZNCC 模板相似度与 SVM 后验概率进行联合评分,用

以补充分类器在边缘模糊样本上的判别信息。虽然该融合策略在当前测试集上的总体准确率未产生明显增量，但其为后续相似字形的结构修正提供了重要的辅助依据。最终，在引入针对 0/9、3/8、5/6 等相似字形的结构启发式后处理模块后，系统在 16 个测试集目标数字中正确识别 15 个，总体目标数字准确率达到 93.75% (15/16)。

上述消融结果表明，线性 SVM 分类器和结构先验后处理是系统性能提升的关键环节。其中，SVM 提供了基于高维特征的主要分类能力，结构后处理则进一步缓解了小样本条件下相似数字之间的混淆问题。但与此同时，系统仍未完全消除仿真样本中由反光、背景干扰和非数字字符引起的误检或误识别现象，说明该方法在复杂场景下仍有进一步优化空间。




图 4：消融分析。模板匹配、SVM 和融合预测准确率偏低；加入题目先验和结构修正后，闭集目标数字准确率达到 15/16。

5.3 综合端到端识别性能

在确立了前述的最优超参数配置 (linear_C0.5) 并验证了多阶段流水线架构的合理性后，本研究在给定的闭集测试集上对系统的端到端综合识别性能进行了基准测试。该测试集包含两张纯净场景样本 (plate_1.jpeg 和 plate_2.jpeg) 以及

两张包含复杂环境干扰的仿真样本（real_1.jpg 和 real_2.jpg），合计涵盖 16 个目标数字实例。

样本名称	给定真实后五位	属于数字的真实位置	系统选中位置	系统预测输出序列	真实数字基准	最终判定
plate_1.jpeg	87459	第 1,2,3,4,5 位	第 1,2,3,4,5 位	87459	87459	Correct
plate_2.jpeg	01236	第 1,2,3,4,5 位	第 1,2,3,4,5 位	01236	01236	Correct
real_1.jpg	X688A	第 2,3,4 位	第 3,4,5 位	884	688	Incorrect
real_2.jpg	AN920	第 3,4,5 位	第 3,4,5 位	920	920	Correct

表 2：4 张测试集样本上目标数字的端到端提取与解码情况。

实验结果表明，在经过严密参数校准与结构后处理干预后，分类矩阵的非零计数严格集中于主对角线上。

具体而言，针对纯净样本，系统成功剔除了前置的汉字与英文字符，实现了 100.0% 的数字分类准确率。但在仿真复杂样本中，受强反光、车身纹理、背景字符和非数字槽位影响，系统并未完全正确完成数字与非数字判定。运行结果显示，仿真样本数字检测 F1 为 83.33%，仿真样本目标数字端到端识别准确率为 83.33%。综合 4 张测试图像共 16 个目标数字，系统正确识别 15 个，总体目标数字准确率为 93.75%。




图 5：闭集目标数字混淆矩阵。图中统计了 15 个被正确输出的目标数字，均落在主对角线；real_1.jpg 中另有 1 个目标数字发生漏检，未形成有效分类输出。

然而，必须客观且审慎地指出，本实验结果仍具有明显的场景局限性与样本依赖性。系统虽然在两张纯净样本上实现了 100.0% 的数字识别准确率，但在仿真复杂样本中并未完全正确完成数字与非数字槽位判定。具体而言，real_1.jpg 中第 2 位真实数字“6”被漏检，而第 5 位非数字字符“A”被误判为数字，导致仿真样本数字检测 F1 为 83.33%，总体目标数字准确率为 93.75%（15/16）。

从统计学与模式识别的角度来看，本次测试集规模较小，仅包含 4 张图像和 16 个目标数字，且样本字体、车牌结构和干扰类型均较为受限。因此，当前结果只能说明该系统在给定闭集小样本条件下具有较好的可解释性和工程可行性，不能被过度解读为具备开放道路场景下的通用泛化能力。后续仍需引入更多真实道路样本，并针对强反光、复杂背景、非数字字符干扰和阈值筛选策略进行进一步验证。

第6章 局限性与未来展望

尽管本系统在给定闭集测试集上取得了较高的目标数字识别准确率，但实验结果仍存在一定局限，不能简单等同于开放道路环境下的通用识别能力。首先，本实验仅基于 4 张测试图像和 16 个目标数字进行评价，测试规模较小，且样本类型相对固定。

因此，93.75% 的总体目标数字准确率更多反映了系统在当前闭集、小样本、已知干扰类型条件下的有效性，不能直接说明模型在雨雪天气、夜间成像、强遮挡、运动模糊、不同拍摄角度以及多类型车牌场景中具有同等泛化性能。

其次，系统在仿真复杂样本中仍出现了数字或非数字槽位判定错误。这说明当前方法虽然能够利用车牌版式先验和数字数量先验降低背景干扰，但在面对反光、车身纹理、非数字字符以及局部笔画缺失时，仍可能发生漏检或误检。尤其是在仿真样本中，字符区域较小、边缘模糊、对比度不足，导致分割结果和后续分类结果之间存在误差传递现象。

此外，本文所引入的结构启发式后处理模块依赖于特定字体下的数字拓扑特征，例如 0/9 的闭环与尾部差异、3/8 的开口结构差异、5/6 的局部笔画密度差异等。这类规则具有较强的可解释性，但也带有一定的人工设计色彩。一旦车牌字

体发生变化，或字符因污损、反光、压缩失真而破坏原有笔画结构，相关规则阈值就需要重新校准，否则可能影响系统的稳定性。

未来若要进一步提升系统的工程实用价值，应从以下几个方面展开改进：

1. 扩充真实道路场景数据集，引入不同地区、不同车牌类型、不同光照和天气条件下的样本，并采用严格的训练集、验证集、测试集划分方式进行评估。
2. 在保持模型可解释性的基础上，引入更稳定的字符检测与分割方法，减少前端定位错误对后端识别结果的影响。
3. 将当前的固定规则后处理逐步改进为数据驱动的概率校正机制，使系统能够根据样本分布自动调整判别边界。
4. 引入置信区间、错误案例统计和消融对比，从而更全面地评价系统在小样本条件下的鲁棒性与适用边界。




图 6：固定阈值在仿真样本上的敏感性分析。实验表明，单一固定阈值难以稳定适应复杂样本中的反光、模糊和非数字干扰，因此最终流程采用题目给定的 top-3 数字槽位先验，而不是将某一固定阈值作为通用泛化规则。

结 论

综上所述,本文围绕极小样本条件下的车牌数字识别任务,设计并实现了一套基于结构先验与混合特征的多阶段识别系统。系统流程涵盖数据读取、模板扩增、车牌定位、底色自适应二值化、字符分割、字形规范化、混合特征提取、SVM 分类以及结构启发式后处理等环节,形成了较为完整的端到端车牌数字识别框架。

实验结果表明,在仅依赖 0—9 共 10 张标准数字模板的条件下,通过仿射扰动、形态学扰动和多维特征融合,系统能够在给定闭集测试集上取得较好的识别效果。其中,纯净样本数字识别率达到 100.0%;在包含反光、背景干扰和尺度变化的仿真复杂样本上,数字定位 F1 分数与目标数字识别准确率仍保持在 83.33%;横跨全部测试样本的总体目标数字准确率达到 93.75% (15/16)。

从消融实验结果来看,单一模板匹配方法难以充分适应真实车牌图像中的光照变化和字形形变,而引入 HOG、行列投影、前景密度和宽高比等混合特征后,线性 SVM 分类器显著提升了系统的基础判别能力。在此基础上,ZNCC 模板相似度融合与结构启发式后处理进一步缓解了 0/9、3/8、5/6 等相似数字之间的混淆问题,体现出人工先验知识与机器学习方法相结合的优势。

总体而言,本文方法在小样本、闭集约束和强先验任务条件下具有较好的可解释性、可复现性和工程可操作性。与此同时,实验也表明,该系统在复杂仿真样本中仍存在非数字误检和目标数字漏检问题,尚不能直接推广为开放道路环境下的工业级 ANPR 方案。后续工作仍需在更大规模真实数据集、更复杂场景条件以及更严格的统计验证框架下进一步测试和优化。

致 谢

本次车牌数字识别系统实验与报告的顺利完成，离不开各方的支持与帮助，在此致以诚挚的感谢。

首先，感谢苏州科技大学沈忠伟老师的悉心教导与专业指导。在《模式识别 A》课程学习及课程设计期间，老师倾囊相授专业知识，凭借扎实的学术功底，针对极小样本识别、算法可复现性等核心问题给予精准指导，为本次识别系统框架的构建与算法优化提供了核心理论支撑，让我们得以规范、高效地完成本次研究任务。

其次，感谢团队的携手合作。在项目开发、代码调试、实验分析与报告撰写的全过程中，我们分工明确、互帮互助，共同攻克了图像强反光、复杂背景干扰等技术难点，顺利完成特征优化、参数调试、实验核验等各项工作，凝聚了团队协作的力量。

同时，感谢 OpenCV、Scikit-learn 开源开发团队及开源社区的技术支持。完善的开源工具与底层技术框架，为系统开发提供了极大便利，有效保障了实验结果的准确性与可复现性。

作为大二学生，本次课程设计是我们初次系统性开展模式识别项目实践的宝贵经历。前路漫漫，未来我们将继续潜心学习、勇于探索，在专业领域中不断提升自我。

参 考 文 献

- [1] LUBNA M, SHAH S A A. Automatic number plate recognition: A detailed survey of relevant algorithms[J]. *Sensors*, 2021, 21(9): 3028.
- [2] DALAL N, TRIGGS B. Histograms of oriented gradients for human detection[C]// *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2005, 1: 886-893.
- [3] CORTES C, VAPNIK V. Support-vector networks[J]. *Machine Learning*, 1995, 20(3): 273-297.
- [4] DU S, IBRAHIM M, SHEHATA M, et al. Automatic license plate recognition (ALPR): A state-of-the-art review[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2012, 23(2): 311-325.
- [5] WANG Y, YAO Q, KWOK J T, et al. Generalizing from a few examples: A survey on few-shot learning[J]. *ACM Computing Surveys (CSUR)*, 2020, 53(3): 1-34.
- [6] OTSU N. A threshold selection method from gray-level histograms[J]. *IEEE Transactions on Systems, Man, and Cybernetics*, 1979, 9(1): 62-66.
- [7] SHASHIRANGANA J, PADMASIRI H, MEEDENIYA D, et al. Automated license plate recognition: A survey on methods and techniques[J]. *IEEE Access*, 2020, 8: 11203-11225.
- [8] CHANG S L, CHEN L S, CHUNG Y C, et al. Automatic license plate recognition[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2004, 5(1): 42-53.
- [9] XIE L, AHMAD T, JIN L, et al. A new architecture for multi-style license plate recognition in complex scenes[J]. *Pattern Recognition*, 2018, 73: 147-161.
- [10] MUFTI N, SHAH S A A. Automatic number plate recognition using HOG and SVM[C]// *International Conference on Computing, Mathematics and Engineering Technologies (iCoMET)*. IEEE, 2020: 1-5.
- [11] PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine learning in Python[J]. *Journal of Machine Learning Research*, 2011, 12: 2825-2830.
- [12] LAROCA R, SEVERO E, ZANLORENSI L A, et al. A robust real-time automatic license plate recognition system on the edge[J]. *IEEE Access*, 2021, 9: 139151-139167.

- [13] ANAGNOSTOPOULOS C N E, ANAGNOSTOPOULOS I E, LOUMOS V, et al. A license plate-recognition algorithm for intelligent transportation system applications[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2006, 7(3): 377-392.
- [14] GONZALEZ R C, WOODS R E. *Digital Image Processing*[M]. 4th ed. Pearson, 2018.
- [15] SILVA S M, JUNG C R. Real-time license plate detection and recognition using deep convolutional neural networks[C]// *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017: 2549-2556.
- [16] BAFOKA M, KASAD R, SHARMA M. Analysis of projection profiles for character segmentation in automatic number plate recognition[J]. *International Journal of Computer Applications*, 2017, 165(8): 24-29.
- [17] FEI-FEI L, FERGUS R, PERONA P. One-shot learning of object categories[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2006, 28(4): 594-611.
- [18] JAIN A K, DUIN R P W, MAO J. Statistical pattern recognition: A review[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2000, 22(1): 4-37.
- [19] PAN S J, YANG Q. A survey on transfer learning[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2009, 22(10): 1345-1359.
- [20] VISHWANATHAN S V N, MURTY M N. SSVM: a generic SVM solver[C]// *Proceedings of the Thirteenth ACM International Conference on Information and Knowledge Management*. 2004: 523-532.